ESPRIT UNIVERSITY

Projet ML Appliqué

Système prédictif pour le suivi académique et l'employabilité des étudiants

Validation Phase 2 — Semaine du 30 Mars 2026

10 000	33	3	9
Étudiants	Variables	Objectifs ML	Modèles

01 Introduction Générale

Ce projet utilise un dataset de 10 000 étudiants avec 33 variables pour construire des modèles de Machine Learning capables d'améliorer le suivi académique, de prédire la réussite scolaire et d'optimiser l'employabilité.

Les 3 grands axes du projet :

A Suivi des Profils Étudiants

Classifier automatiquement chaque étudiant dans un profil (Académique, Carriériste, Social, Équilibré, À risque) pour mieux personnaliser le suivi pédagogique.

B Prédiction de la Réussite

Prédire le taux de réussite de chaque étudiant (0 à 100%) à partir de ses données académiques et d'engagement pour déclencher un accompagnement ciblé.

C Amélioration Employabilité

Évaluer le niveau d'employabilité (Low / Average / Good / Excellent) et recommander des stages et actions concrètes pour mieux préparer les étudiants au marché du travail.

Données synthétiques générées pour ESPRIT University 2025/2026 | Train/Test : 80% / 20%

02 Problématique

Quels sont les défis actuels des universités dans le suivi de leurs étudiants ?

01 Décrochage scolaire difficile à anticiper

Aucun système ne permet d'identifier les étudiants en difficulté AVANT l'échec. Les interventions sont toujours après coup.

02 Manque de suivi personnalisé

Les plateformes LMS (ex. Moodle) collectent des données mais ne génèrent pas d'alertes ni de recommandations individuelles.

03 Faible taux d'insertion professionnelle

Peu de lien entre le parcours académique et la préparation à l'emploi. Les étudiants ne savent pas comment améliorer leur employabilité.

04 Absence d'outils prédictifs pour orienter les décisions

Les rapports pédagogiques sont réactifs (basés sur les résultats passés) et non proactifs (anticipant les problèmes futurs).

Question centrale : Comment transformer les données académiques brutes en décisions pédagogiques proactives ?

03 Étude et Critique de l'Existant

Que proposent les solutions actuelles et quelles sont leurs limites ?

Solution	Ce qu'elle fait	Ce qu'elle NE fait PAS	Impact
LMS (Moodle)	Suivi des cours, quiz, présences	Pas de prédiction, pas d'alerte	Réactif
ERP Université	Notes, inscriptions, historique	Aucune capacité ML ou prédictive	Statique
Tableaux BI	Rapports, graphiques agrégés	Données passées uniquement	Limité
Conseil manuel	Suivi humain individuel	Non scalable pour 10 000 étudiants	Lent
Notre solution ML	**Collecte + prédiction en temps réel**	**—**	**Proactif**

Conclusion : Les outils existants collectent les données mais ne les exploitent pas pour prédire ou prévenir.

04 Solution Proposée

Notre approche : Un pipeline ML complet articulé en 3 objectifs distincts

OBJECTIF A

Classification des Profils

Cible : *profile_label*

Type : Classification (5 classes)

Modèles :

Logistic Reg. / Random Forest / Gradient Boosting

OBJECTIF B

Prédiction du Taux de Réussite

Cible : *predicted_success_rate*

Type : Régression (valeur 0–100)

Modèles :

Ridge / Random Forest Reg. / Gradient Boosting Reg.

OBJECTIF C

Amélioration de l'Employabilité

Cible : *employability_level*

Type : Classification (4 classes)

Modèles :

Decision Tree / Random Forest / Gradient Boosting

Chaque objectif compare 3 modèles différents → 9 modèles au total | Métriques : Accuracy, F1-Score, R^2, MAE, RMSE

05 Objectifs Métier et Objectifs Data Science

Chaque objectif est défini selon deux niveaux : ce que l'université veut atteindre (métier) et ce que le modèle doit faire (data science).

Objectifs Métier (minimum 3)

- Améliorer le suivi individuel des étudiants
- Réduire le taux de décrochage scolaire
- Faciliter la gestion pédagogique personnalisée
- Augmenter le taux d'insertion professionnelle
- Générer des alertes proactives pour les enseignants
- Recommander des stages adaptés au profil étudiant

Objectifs Data Science (minimum 3)

- Classifier les profils en 5 catégories (Obj. A)
- Prédire le taux de réussite en continu (Obj. B)
- Classifier le niveau d'employabilité en 4 classes (Obj. C)
- Comparer 3 modèles ML par objectif = 9 modèles
- Atteindre Accuracy ≥ 80% pour les classifications
- Atteindre un $R^2 \geq 0.75$ pour la régression

Exigence : minimum 3 objectifs par groupe — Remplie et dépassée (6 objectifs de chaque côté)

06 Méthodologie de Travail

Approche CRISP-DM adaptée au projet avec une stratégie anti-leakage rigoureuse

1. Compréhension du problème
2. Collecte & chargement
3. Analyse exploratoire (EDA)
4. Préparation des données
5. Modélisation ML

Détails méthodologiques importants :

Stratégie Anti-Leakage

Pour chaque objectif, les variables cibles des autres objectifs sont exclues des features. Exemple : pour prédire profile_label (Obj A), on exclut predicted_success_rate et employability_score.

Découpage Train / Test

80% des données pour l'entraînement, 20% pour le test. Pour les classifications, on applique la stratification (stratify=y) pour garder les proportions de classes.

Évaluation des Modèles

Classification → Accuracy + F1-Score macro. Régression → R^2 (qualité globale) + MAE (erreur moyenne) + RMSE (pénalise les grosses erreurs). Tous les résultats sont comparés dans un tableau récapitulatif.

Encodage : LabelEncoder pour les variables catégorielles | StandardScaler pour la régression (Objectif B)

07 Phase 1 — Collecte et Compréhension des Données

Le dataset contient 10 000 lignes × 33 colonnes décrivant le parcours académique, l'engagement et l'employabilité de chaque étudiant.

Catégories de variables :

Identification	4 variables	student_id, first_name, last_name, class_level
Académique	8 variables	nb_courses_enrolled, nb_courses_completed, avg_course_progress, nb_quiz_taken, avg_quiz_score, quiz_pass_rate...
Engagement	7 variables	nb_events_attended, nb_clubs_joined, login_frequency_per_week, engagement_score, nb_competitions, competition_wins...
Stage & Emploi	5 variables	has_internship, internship_duration_days, nb_complaints, complaint_resolved_rate, suggested_internship_domain...
Cibles ML (Obj A)	2 variables	profile_label → 5 classes : Academic Focused, Career Oriented, Balanced, Socially Active, At Risk
Cibles ML (Obj B)	2 variables	predicted_success_rate (0–100) | predicted_grade (Fail/Pass/Merit/Distinction)
Cibles ML (Obj C)	5 variables	employability_score, employability_level (Low/Average/Good/Excellent), internship_recommendation...

EDA réalisée : Aucune valeur manquante | Distribution des classes vérifiée | Corrélations analysées | Pas de doublons

07b Phase 1 — Préparation des Données (Preprocessing)

Étapes de préparation appliquées avant chaque modélisation :

1

Suppression des identifiants

Les colonnes non utiles au modèle (student_id, first_name, last_name) sont supprimées car elles n'apportent aucune information prédictive.

2

Encodage (LabelEncoder)

Les variables textuelles (class_level, profile_label, employability_level...) sont transformées en valeurs numériques grâce au LabelEncoder de Scikit-learn.

3

Sélection des features

Pour chaque objectif, les features sont soigneusement sélectionnées. Les variables cibles des autres objectifs sont exclues pour éviter le data leakage.

4

Normalisation (StandardScaler)

Pour l'Objectif B (régression), les features sont normalisées avec StandardScaler pour que toutes les variables aient la même échelle.

5

Découpage Train/Test

80% des données pour entraîner le modèle, 20% pour le tester. La stratification est utilisée pour les classifications (Obj A et C).

Objectifs A et C → Classification | Objectif B → Régression | Tous les modèles entraînés séparément

08A Phase 2 — Objectif A : Classification des Profils Étudiants

Objectif : Prédire automatiquement le profil (profile_label) de chaque étudiant parmi 5 classes. | Problème : Classification multiclasse | Split : 80% train / 20% test stratifié

Les 5 classes cibles :

- Academic Focused
- Career Oriented
- Balanced
- Socially Active
- At Risk

Comparaison des 3 Modèles :

A1 — Logistic Regression

Accuracy

82%

F1-Macro : 81% | C=1.0, max_iter=1000

★ MEILLEUR MODÈLE

A2 — Random Forest

Accuracy

91%

F1-Macro : 90% | n_estimators=100, max_depth=8

A3 — Gradient Boosting

Accuracy

89%

F1-Macro : 88% | n_estimators=100, lr=0.1, max_depth=4

08B Phase 2 — Objectif B : Prédiction du Taux de Réussite

Objectif : Prédire le taux de réussite (valeur continue de 0 à 100%). | Problème : Régression | Métriques : R^2 (qualité globale), MAE (erreur moyenne), RMSE (pénalise les grosses erreurs)

Comprendre les métriques :

R^2 : Plus il est proche de 1, meilleur est le modèle (0.87 = très bon).

MAE : Erreur moyenne en points. MAE=5 signifie que la prédiction se trompe de ±5 points en moyenne.

RMSE : Comme le MAE mais pénalise davantage les grosses erreurs.

Comparaison des 3 Modèles de Régression :

B1 — Ridge Regression

R^2 Score

0.72

MAE: 8.4 pts | RMSE: 11.2 pts | alpha=1.0

★ MEILLEUR MODÈLE

B2 — Random Forest Reg.

R^2 Score

0.87

MAE: 5.1 pts | RMSE: 7.8 pts | n=100, max_depth=8

B3 — Gradient Boosting Reg.

R^2 Score

0.85

MAE: 5.6 pts | RMSE: 8.4 pts | n=100, lr=0.1

StandardScaler appliqué avant l'entraînement | R^2=0.87 signifie que le modèle explique 87% de la variance du taux de réussite

08C Phase 2 — Objectif C : Amélioration de l'Employabilité

Objectif : Classifier le niveau d'employabilité de chaque étudiant. | Problème : Classification 4 classes | Classes : Low, Average, Good, Excellent | Split : 80/20 stratifié

Les 4 classes et leur signification :

Low
Peu de compétences, pas de stage

Average
Niveau correct, quelques activités

Good
Bon profil, stage effectué

Excellent
Très engagé, compétitions, stage long

Comparaison des 3 Modèles de Classification :

C1 — Decision Tree

Accuracy

78%

F1-Macro : 77% | max_depth=6

★ MEILLEUR MODÈLE

C2 — Random Forest

Accuracy

90%

F1-Macro : 89% | n=100, max_depth=8

C3 — Gradient Boosting

Accuracy

88%

F1-Macro : 87% | n=100, lr=0.1, max_depth=4

09 Récapitulatif Complet — 9 Modèles Comparés

Résumé de tous les modèles entraînés avec leurs performances et le meilleur sélectionné par objectif :

Obj.	Problème	Modèle	Métrique 1	Score 1	Métrique 2	Score 2	Résultat
A	Classification	Logistic Regression	Accuracy	82.0%	F1-Macro	81.0%	✓ Correct
A	**Classification**	**Random Forest ★**	**Accuracy**	91.0%	**F1-Macro**	90.0%	★ MEILLEUR
A	Classification	Gradient Boosting	Accuracy	89.0%	F1-Macro	88.0%	✓ Très bon
B	Régression	Ridge Regression	R^2	0.72	MAE	8.4 pts	✓ Correct
B	**Régression**	**Random Forest Reg. ★**	**R^2**	0.87	**MAE**	5.1 pts	★ MEILLEUR
B	Régression	Gradient Boosting Reg.	R^2	0.85	MAE	5.6 pts	✓ Très bon
C	Classification	Decision Tree	Accuracy	78.0%	F1-Macro	77.0%	✓ Correct
C	**Classification**	**Random Forest ★**	**Accuracy**	90.0%	**F1-Macro**	89.0%	★ MEILLEUR
C	Classification	Gradient Boosting	Accuracy	88.0%	F1-Macro	87.0%	✓ Très bon

Conclusion : Random Forest est le meilleur modèle pour les 3 objectifs | 9 modèles entraînés, évalués et comparés

10 Outils et Technologies Utilisés

L'ensemble du projet a été développé avec des outils open-source standards de la Data Science :

Python 3.10

Langage de programmation principal

Traitement des données, développement des modèles ML, visualisations.

Jupyter Notebook / Google Colab

Environnement de développement interactif

Écriture du code, test des modèles, affichage des résultats en temps réel.

Pandas & NumPy

Manipulation et analyse des données

Chargement du CSV, sélection des features, calculs statistiques, encodage.

Matplotlib & Seaborn

Visualisation des données

Graphiques EDA (distributions, corrélations), courbes de comparaison des modèles.

Scikit-learn

Bibliothèque Machine Learning principale

Modèles (LR, RF, GB, DT, Ridge), Preprocessing (StandardScaler, LabelEncoder), Métriques (accuracy, F1, R^2, MAE, RMSE).

XGBoost / GradientBoosting

Modèles d'ensemble avancés

Gradient Boosting Classifier (Obj A, C) et Gradient Boosting Regressor (Obj B) via Scikit-learn.

Tous les outils sont gratuits et open-source. Le projet tourne sur Google Colab sans installation locale.

11 — Conclusion et Perspectives

Ce que nous avons accompli

- Phase 1 complète : chargement, EDA, préparation des données de 10 000 étudiants
- Stratégie anti-leakage rigoureuse appliquée pour les 3 objectifs
- 9 modèles ML entraînés, évalués et comparés (3 par objectif)
- Accuracy ≥ 91% pour Objectif A (Random Forest)
- R^2 = 0.87 pour Objectif B (Random Forest Regressor)
- Accuracy ≥ 90% pour Objectif C (Random Forest)
- Toutes les parties de la validation Phase 2 couvertes

Perspectives et améliorations futures

- Optimisation des hyperparamètres (GridSearchCV)
- Déploiement en production via Streamlit ou FastAPI
- Ajout de l'explicabilité des modèles (SHAP values)
- Collecte de vraies données réelles ESPRIT
- Dashboard interactif pour les enseignants en temps réel
- Deep Learning : réseaux de neurones pour Obj C
- AutoML pour sélection automatique des meilleurs modèles